

Probabilidade Condicional e Regra de Bayes

Prof. Diego Mello

Agosto/2025

Grupo: _____ Nota: _____

INSTRUÇÕES: Leia atentamente o conteúdo teórico e instruções antes de resolver a lista. Nela, são trabalhados aspectos de aplicação da teoria sobre probabilidade, assim como implementação computacional de casos usando simulação de Monte Carlo via geração de números aleatórios. A lista deve ser feita em grupo de até 5 pessoas. Sugere-se que as implementações sejam feitas em Python 3 ou [R], mas qualquer linguagem de programação que seja capaz de gerar números aleatórios pode ser utilizada. O conteúdo deve ser entregue na plataforma Classroom até a data e hora especificadas, sem exceção. Exercícios feitos a mão precisam ser digitalizados em formato .pdf antes da submissão.

1 Parte I - Conceitos de Probabilidade

Probabilidade Condicional

A probabilidade, em sua essência, lida com a incerteza. No entanto, o mundo real raramente nos apresenta cenários de incerteza pura. Frequentemente, possuímos informações parciais que podem influenciar a chance de um evento ocorrer. É aqui que entra a *Probabilidade Condicional*, um conceito fundamental que nos permite recalcular a probabilidade de um evento à luz de informações adicionais.

Formalmente, a probabilidade de um evento A ocorrer, dado que um evento B já ocorreu, é denotada por $P(A|B)$. A fórmula para calcular essa probabilidade é:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad \text{em que } P(B) > 0$$

Aqui, $P(A \cap B)$ representa a probabilidade de que os eventos A e B ocorram simultaneamente, e $P(B)$ é a probabilidade do evento que já sabemos ter ocorrido. A intuição por trás dessa fórmula é que o evento B restringe o nosso “universo” de resultados possíveis. Em vez de considerar todo o espaço amostral, nós focamos apenas nos resultados em que B é verdadeiro, e a probabilidade de A é então a proporção da intersecção $A \cap B$ dentro desse novo espaço amostral.

Exemplo 1: Sequência de Bits

Uma sequência de 4 bits (zeros e uns) é gerada aleatoriamente, de modo que cada uma das 16 sequências possíveis tem a mesma probabilidade de ocorrer. Sejam os eventos:

- **Evento E:** A sequência contém pelo menos dois zeros consecutivos:

$$E = \{0000, 0001, 0010, 0011, 0100, 1000, 1001, 1100\}, \quad |E| = 8, \quad P(E) = \frac{8}{16}$$

- **Evento F:** A sequência de bits começa com 0. As sequências possíveis são aquelas onde o primeiro bit é 0, e os outros três bits podem ser 0 ou 1.

$$F = \{0000, 0001, 0010, 0011, 0100, 0101, 0110, 0111\}, \quad |F| = 8, \quad P(F) = \frac{8}{16}$$

Qual é a probabilidade de a sequência conter pelo menos dois zeros consecutivos, dado que o primeiro bit é 0?

Pela definição, é $P(E|F) = \frac{P(E \cap F)}{P(F)}$.

A intersecção de E e F é o conjunto de sequências que começam com 0 e têm pelo menos dois zeros consecutivos:

- Se a sequência começa com “00”, ela contém dois zeros consecutivos. As possibilidades são 0000, 0001, 0010, 0011.
- Se a sequência começa com “01”, o único lugar para ter dois zeros consecutivos é no final, o que nos dá a sequência 0100.

Ao todo:

$$E \cap F = \{0000, 0001, 0010, 0011, 0100\}, \quad |E \cap F| = 5, \quad P(E \cap F) = \frac{5}{16}$$

Pela fórmula da probabilidade condicional:

$$P(E|F) = \frac{P(E \cap F)}{P(F)} = \frac{5/16}{8/16} = \frac{5}{8}$$

A probabilidade de uma sequência de 4 bits ter pelo menos dois zeros consecutivos, dado que seu primeiro bit é 0, é de $5/8$ ou 62.5%. A priori, sem essa informação, a probabilidade de ter dois zeros consecutivos era de $8/16$ ou 50%.

Teorema da Probabilidade Total

Muitas vezes, a probabilidade de um evento de interesse, digamos A , não é diretamente conhecida, mas podemos calculá-la se soubermos as probabilidades condicionais de A com relação a um conjunto de outros eventos mutuamente exclusivos e exaustivos. Isso é o que o *Teorema da Proba-*

bilidade Total nos permite fazer.

Suponha que o espaço amostral de um experimento possa ser particionado por um conjunto de eventos $B_1, B_2, \dots, B_n$, de tal forma que cada par de eventos seja mutuamente exclusivo ($B_i \cap B_j = \emptyset$ para $i \neq j$) e a união de todos eles cubra o espaço amostral ($B_1 \cup B_2 \cup \dots \cup B_n = \Omega$). O Teorema da Probabilidade Total afirma que a probabilidade de qualquer evento A pode ser calculada como:

$$P(A) = \sum_{i=1}^n P(A | B_i) \cdot P(B_i)$$

Este teorema é extremamente útil em situações onde um evento A pode ocorrer por diversas “causas” ou “caminhos” distintos. Ele nos permite somar as probabilidades de cada um desses caminhos para encontrar a probabilidade total de A .

Exemplo 2: Doença Rara

Imagine que você está em um hospital e deseja saber a probabilidade de um paciente aleatório testar positivo para uma doença rara. A precisão do teste depende da condição real do paciente.

- A probabilidade de um paciente ter a doença é de 1%: $P(D) = 0.01$.
- A probabilidade de um paciente não ter a doença é de 99%: $P(D') = 1 - P(D) = 0.99$.
- O teste é 95% preciso para pacientes doentes (probabilidade de dar positivo, dado que o paciente está doente): $P(P|D) = 0.95$.
- O teste é 98% preciso para pacientes saudáveis (probabilidade de dar negativo, dado que o paciente não está doente). Consequentemente, a probabilidade de um falso positivo é de 2%: $P(P|D') = 0.02$.

Para encontrar a probabilidade total de um teste dar positivo, consideramos os dois caminhos possíveis para esse resultado:

- O paciente está doente e o teste deu positivo (verdadeiro positivo).
- O paciente não está doente e o teste deu positivo (falso positivo).

Usando o Teorema da Probabilidade Total, somamos as probabilidades desses dois caminhos:

$$\begin{aligned} P(P) &= P(P | D) \cdot P(D) + P(P | D') \cdot P(D') \\ &= (0.95) \cdot (0.01) + (0.02) \cdot (0.99) \\ &= 0.0095 + 0.0198 \\ &= 0.0293 \end{aligned}$$

Portanto, a probabilidade de um paciente aleatório testar positivo é de 2.93%. Note que este número é significativamente maior que a probabilidade da doença em si, devido à taxa de falsos positivos em uma grande população de pessoas saudáveis.

Regra de Bayes

A *Regra de Bayes*, ou Teorema de Bayes, é uma das fórmulas mais importantes na teoria da probabilidade, pois permite atualizar nossa crença sobre a probabilidade de uma hipótese com base em novas evidências. Se a probabilidade condicional nos diz a chance de um evento dado outro, a Regra de Bayes inverte essa relação. Ela nos permite calcular a probabilidade de uma causa (B) dado que um efeito (A) foi observado.

A fórmula é derivada diretamente da definição de Probabilidade Condicional e do Teorema da Probabilidade Total:

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

Onde $P(A)$ pode ser expandido usando o Teorema da Probabilidade Total.

Nesta fórmula, $P(B)$ é a **probabilidade a priori** (nossa crença inicial sobre a hipótese B antes de ver a evidência A), $P(A|B)$ é a **verossimilhança** (a probabilidade da evidência A dado que a hipótese B é verdadeira), e $P(B|A)$ é a **probabilidade a posteriori** (a nossa crença atualizada sobre a hipótese B após ver a evidência A).

A Regra de Bayes é a base para a inferência bayesiana, um ramo da estatística que tem aplicações em aprendizado de máquina, diagnóstico médico e muitos outros campos.

Exemplo 3: Filtro de Spam e a Regra de Bayes

Imagine um filtro de e-mail que usa a Regra de Bayes para determinar se uma nova mensagem é spam. Com base em dados históricos, o sistema conhece as seguintes probabilidades:

Probabilidade a Priori: A chance de um e-mail aleatório ser spam.

- Suponha que **22%** de todos os e-mails recebidos são spam. $P(S) = 0.22$ $P(S') = 1 - 0.22 = 0.78$

Evidência: A ocorrência de uma palavra específica, como a palavra “ganhe”.

- O sistema sabe que a palavra “ganhe” aparece em 80% dos e-mails de spam. $P(G|S) = 0.80$
- A palavra “ganhe” também aparece em 10% dos e-mails que não são spam. $P(G|S') = 0.10$

Agora, a pergunta é: **Qual a probabilidade de uma nova mensagem ser spam, dado que ela contém a palavra “ganhe”?**

Para resolver isso, usamos a Regra de Bayes:

$$P(S|G) = \frac{P(G|S) \cdot P(S)}{P(G)}$$

O denominador, $P(G)$, é a **probabilidade total** de a palavra “ganhe” aparecer em qualquer e-mail (seja ele spam ou não).

Precisamos calculá-lo primeiro, usando o Teorema da Probabilidade Total:

$$P(G) = P(G|S) \cdot P(S) + P(G|S') \cdot P(S')$$

$$P(G) = (0.80) \cdot (0.22) + (0.10) \cdot (0.78) = 0.176 + 0.078 = 0.254$$

Aplicando a Regra de Bayes:

$$P(S|G) = \frac{(0.80) \cdot (0.22)}{0.254} = \frac{0.176}{0.254} \approx 0.693$$

Conclusão: Nossa crença inicial de que um e-mail aleatório era spam era de **22%**. No entanto, após receber a evidência de que a palavra “ganhe” estava presente, nossa probabilidade a posteriori (a crença atualizada) subiu para **69.3%**.

Este exemplo demonstra o poder da Regra de Bayes: ela permite que um sistema de aprendizado de máquina simples “aprenda” com os dados, atualizando suas probabilidades e tomando uma decisão mais informada.

O filtro de e-mail, por exemplo, pode usar este resultado para decidir se move a mensagem para a pasta de spam sempre que uma evidência E suportar a decisão, por exemplo, aplicando um limiar:

$$P(S|E) \geq 0.5$$

2 Parte II - Exercícios

A seção anterior introduz conceitos sobre probabilidade condicional, total e regra de Bayes. Nesta seção iremos exercitar estes conceitos aplicando-os a exercícios.

Exercício 1. *Suponha que 8% de todos os ciclistas usam esteroides, que um ciclista que usa esteroides testa positivo para esteroides 96% do tempo e que um ciclista que não usa esteroides testa positivo para esteroides 9% do tempo. Qual é a probabilidade de um ciclista selecionado aleatoriamente que testa positivo para esteroides realmente usar esteroides?*

Eventos:

- E : O ciclista usa esteroides.
- E' : O ciclista não usa esteroides.
- P : O ciclista testa positivo para esteroides.

Exercício 2. Um teste laboratorial de sangue é 99% eficaz na detecção de uma determinada doença quando ela, de fato, está presente. No entanto, o teste também produz um resultado “falso positivo” para 1% das pessoas saudáveis testadas. (Ou seja, se uma pessoa saudável for testada, então, com probabilidade de 0.01, o resultado do teste indicará que ela tem a doença.) Se 0.5% da população realmente tem a doença, qual é a probabilidade de uma pessoa ter a doença, dado que o resultado do seu teste é positivo?

Eventos:

- D : A pessoa tem a doença.
- $\bar{D}$: A pessoa não tem a doença (é saudável).
- P : O resultado do teste é positivo.

Exercício 3. Uma fábrica produz componentes eletrônicos usando duas máquinas, $M1$ e $M2$. A produção da máquina $M1$ corresponde a 60% do total, enquanto a produção da máquina $M2$ é de 40%. O controle de qualidade histórico da fábrica mostra que a taxa de componentes defeituosos de $M1$ é de 3%, e a taxa de $M2$ é de 5%.

Eventos:

- $M1$: O componente foi produzido pela máquina $M1$.
- $M2$: O componente foi produzido pela máquina $M2$.
- D : O componente tem defeito.

Pergunta-se: (a) Qual a probabilidade total de um componente aleatório ser defeituoso?
(b) Se um componente é defeituoso, qual a probabilidade de ele ter vindo da máquina $M1$?

Exercício 4. Um sistema de servidor é composto por dois módulos, A e B , que operam de forma independente. O sistema pode falhar se o hardware ou o software de qualquer módulo falhar.

A probabilidade de o módulo A ser escolhido para uma operação é de 60%, enquanto a do módulo B é de 40%. As probabilidades de falha de software para os módulos A e B são 0.05 e 0.02, respectivamente. As probabilidades de falha de hardware são 0.01 para o módulo A e 0.03 para o módulo B .

Assumindo que as falhas de hardware e software em cada módulo são eventos mutuamente exclusivos, qual é a probabilidade de o sistema falhar em uma operação aleatória?

Eventos:

- A : Módulo A é escolhido.
- B : Módulo B é escolhido.
- F : O sistema falha.

- F_A : O módulo A falha.
- F_B : O módulo B falha.
- H_A : Falha de hardware no módulo A.
- H_B : Falha de hardware no módulo B.
- S_A : Falha de software no módulo A.
- S_B : Falha de software no módulo B.

Exercício 5. Em uma rede de computadores, os pacotes de dados são roteados por um switch. Os pacotes podem vir de três fontes diferentes: Servidor 1, Servidor 2 e Servidor 3. A probabilidade de um pacote vir de cada servidor é de 0.40, 0.35 e 0.25, respectivamente. As probabilidades de um pacote ser um pacote de vídeo, dado que ele veio de cada servidor, são as seguintes:

- $P(V|S_1) = 0.60$
- $P(V|S_2) = 0.30$
- $P(V|S_3) = 0.80$

Qual é a probabilidade de que um pacote de dados recebido pelo switch seja um pacote de vídeo?

Eventos:

- S_1 : O pacote veio do Servidor 1.
- S_2 : O pacote veio do Servidor 2.
- S_3 : O pacote veio do Servidor 3.
- V : O pacote é um pacote de vídeo.

Exercício 6. Uma empresa de cibersegurança desenvolveu um sistema de detecção de malware para arquivos baixados. O sistema classifica cada arquivo como “malicioso” ou “limpo”. A empresa sabe, por meio de dados históricos, que 2.5% de todos os arquivos baixados contêm malware.

O sistema de detecção tem as seguintes taxas de sucesso:

- A probabilidade de o sistema classificar um arquivo com malware como “malicioso” (verdadeiro positivo) é de 99.5%.
- A probabilidade de o sistema classificar um arquivo limpo como “malicioso” (falso positivo) é de 1%.

Isto posto, qual é a probabilidade de um arquivo ser classificado como “malicioso” pelo sistema de segurança?

Eventos:

- *M: O arquivo contém malware.*
- *M': O arquivo é limpo.*
- *C: O sistema classifica o arquivo como “malicioso”.*

Exercício 7. *Uma empresa de desenvolvimento de software classifica seus projetos em três etapas principais: Desenvolvimento, Teste e Implantação. Um estudo interno revelou a probabilidade de um projeto ser reprovado em cada uma dessas etapas.*

- *70% dos projetos estão na fase de Desenvolvimento, e a probabilidade de um projeto falhar nessa fase é de 10%.*
- *25% dos projetos estão na fase de Teste, e a probabilidade de um projeto falhar nessa fase é de 5%.*
- *5% dos projetos estão na fase de Implantação, e a probabilidade de um projeto falhar nessa fase é de 2%.*

Com base nos dados, determine a probabilidade de um projeto, selecionado aleatoriamente, falhar em qualquer uma das três etapas.

Eventos:

- *D: O projeto está na fase de Desenvolvimento.*
- *T: O projeto está na fase de Teste.*
- *I: O projeto está na fase de Implantação.*
- *F: O projeto falha.*

Exercício 8. *Em um sistema operacional, a falha de um processo pode ser causada por um erro de memória ou por uma falha de acesso a disco. Suponha que 75% das falhas de processo são causadas por um erro de memória, enquanto 25% são causadas por uma falha de acesso a disco.*

Quando um processo falha devido a um erro de memória, a probabilidade de ele ser de alta carga de memória é de 90%. Por outro lado, quando um processo falha devido a uma falha de acesso a disco, a probabilidade de ele ser de alta carga de memória é de 5%.

Se um processo falha, e o log do sistema mostra que ele é de alta carga de memória, qual é a probabilidade de que a causa da falha tenha sido um erro de memória?

Eventos:

- *M*: A falha é causada por um erro de memória.
- *D*: A falha é causada por uma falha de acesso a disco.
- *A*: A falha ocorre em um processo de alta carga de memória.

Exercício 9. Uma empresa de software está testando uma nova interface de usuário. O sistema pode ter uma resposta “lenta” ou “normal”. Um grupo de pesquisa estima que 85% das interações dos usuários têm uma resposta normal, enquanto 15% têm uma resposta lenta.

Em testes controlados, a probabilidade de um usuário abandonar a tarefa (evidência) é de 40% quando a resposta do sistema é lenta, mas é de apenas 5% quando a resposta é normal.

Se um usuário abandona a tarefa durante a interação com o sistema, qual é a probabilidade de que a resposta do sistema estivesse lenta?

Eventos:

- *L*: A resposta do sistema é lenta.
- *N*: A resposta do sistema é normal.
- *A*: O usuário abandona a tarefa.

Exercício 10. Uma linha de produção industrial possui um sensor que detecta falhas em peças. Sabe-se que 0.8% de todas as peças produzidas são defeituosas. O sensor é altamente preciso:

- A probabilidade de o sensor disparar um alarme (evidência) se a peça for realmente defeituosa é de 99.7%.
- A probabilidade de o sensor disparar um alarme se a peça não for defeituosa (falso positivo) é de 2%.

Se o sensor dispara um alarme, qual é a probabilidade de que a peça seja realmente defeituosa?

Eventos:

- *D*: A peça é defeituosa.
- *D'*: A peça não é defeituosa.
- *A*: O sensor dispara um alarme.

3 Parte III - Simulação por Monte Carlo

Seja enunciado do **exercício 1**:

Suponha que 8% de todos os ciclistas usam esteroides, que um ciclista que usa esteroides testa positivo para esteroides 96% do tempo e que um ciclista que não usa esteroides testa positivo para esteroides 9% do tempo. Qual é a probabilidade de um ciclista selecionado aleatoriamente que testa positivo para esteroides realmente usar esteroides?

Sejam os eventos:

- E : O ciclista usa esteroides.
- P : O ciclista testa positivo para esteroides.

O que queremos responder é: qual é $P(E|P)$? Podemos estimar essa probabilidade usando simulação por Monte Carlo. Idéia central: por meio de muitas rodadas de simulação (N), cada qual amostrando a chance do ciclista usar esteróides ($P(E) = 8\%$) e, se usa esteróide, contabilizar se o teste deu positivo (com $P(P|E) = 96\%$), ou ainda se deu positivo mesmo quando o ciclista não usa esteróide (com $P(P|E') = 9\%$). Ao final, fazer a razão das contagens para estimar $P(E|P)$.

A lógica que implementa essa simulação pode ser dada a seguir, em pseudocódigo, no Algoritmo 1

Algoritmo 1 Monte-Carlo-Ciclista(N , $P(E)$, $P(P|E)$, $P(P|E')$)

```
1: cont_pos ← 0
2: cont_ester_pos ← 0
3: for ( $s \leftarrow 1$  to  $N$ ) do
4:   usa ← (random(0,1) <  $P(E)$ )
5:   pos ← false
6:   if (usa) then
7:     if (random(0,1) <  $P(P|E)$ ) then
8:       pos ← true
9:     end if
10:  else
11:    if (random(0,1) <  $P(P|E')$ ) then
12:      pos ← true
13:    end if
14:  end if
15:  if (pos) then
16:    cont_pos ← cont_pos + 1
17:    if (usa) then
18:      cont_ester_pos ← cont_ester_pos + 1
19:    end if
20:  end if
21: end for
22: Return (cont_ester_pos / cont_pos) = 0
```

Cuja implementação em python é algo como segue:

```

import random

def monte_carlo_ciclista(N, p_usa, p_pos_dado_usa, p_pos_dado_nao_usa):
    cont_pos = 0
    cont_ester_pos = 0
    for s in range(N):
        usa = random.random() < p_usa
        pos = False
        if usa:
            if random.random() < p_pos_dado_usa:
                pos = True
        else:
            if random.random() < p_pos_dado_nao_usa:
                pos = True
        if pos:
            cont_pos += 1
            if usa:
                cont_ester_pos += 1
    return cont_ester_pos / cont_pos
print(f"monte_carlo_ciclista(10000000, 0.08, 0.96, 0.09):.4f")

```

Porém, podemos identificar que essa é uma estrutura geral de estimar probabilidades para a regra de Bayes. Sejam: N o número de simulações que a executar via Monte Carlo, $P(A)$ a probabilidade *a priori* de um evento A ; $P(E|A)$ a probabilidade da evidência E , dado que A ocorreu, e $P(E|A')$ a probabilidade da evidência E , dado que A não ocorreu. O Algoritmo 2 estima:

$$P(A|E) = \frac{P(A \cap E)}{P(E)} \approx \frac{\text{contagem da evidência} \wedge \text{a priori}}{\text{contagem da evidência}}$$

Algoritmo 2 Monte-Carlo-Geral-Bayes(N , $P(A)$, $P(E|A)$, $P(E|A')$)

```

1: cont_evidencia ← 0
2: cont_evidencia_e_a_priori ← 0
3: for ( $i \leftarrow 1$  to  $N$ ) do
4:   evento_a_ocorreu ← (random(0,1) <  $P(A)$ )
5:   evidencia_ocorreu ← false
6:   if (evento_a_ocorreu) then
7:     if (random(0,1) <  $P(E|A)$ ) then
8:       evidencia_ocorreu ← true
9:     end if
10:  else
11:    if (random(0,1) <  $P(E|A')$ ) then
12:      evidencia_ocorreu ← true
13:    end if
14:  end if
15:  if (evidencia_ocorreu) then
16:    cont_evidencia ← cont_evidencia + 1
17:    if (evento_a_ocorreu) then
18:      cont_evidencia_e_a_priori ← cont_evidencia_e_a_priori + 1
19:    end if
20:  end if
21: end for
22: Return (cont_evidencia_e_a_priori / cont_evidencia) = 0

```

Isto posto, implementar em linguagem computacional o Algoritmo 2, e confirmar os valores calculados para todos os exercícios que usaram a Regra de Bayes como resolução.

4 Parte IV - Aplicações: classificador Naive Bayes

Naive Bayes

A **Parte II** da nossa lista abordou o cálculo de probabilidades de eventos únicos, e a **Parte II** explorou a simulação para estimar esses resultados. Agora, na **Parte III**, iremos aplicar a teoria de probabilidade para construir um dos classificadores mais simples e, ao mesmo tempo, mais eficientes na área de aprendizado de máquina: o **Classificador Naive Bayes**.

Em sua essência, o Naive Bayes é um algoritmo de classificação que se baseia diretamente no **Teorema de Bayes**. Sua principal função é categorizar dados em classes específicas, como, por exemplo, classificar um e-mail como “spam” ou “não-spam”, ou um diagnóstico médico como “positivo” ou “negativo” para uma doença.

O que o torna “ingênuo” (do inglês, *naive*) é uma suposição extremamente simplificadora: ele assume que a presença de uma característica (ou “atributo”) em uma classe é **independente** da presença de qualquer outra característica. Por exemplo, em um filtro de spam, a presença da palavra “oferta” é considerada independente da presença da palavra “grátis”, mesmo que na vida real essas palavras frequentemente apareçam juntas. Embora essa suposição seja raramente verdadeira, o classificador ainda funciona de forma surpreendentemente eficaz em muitos cenários.

O Teorema de Bayes na Classificação

A Regra de Bayes é o coração do classificador, e sua fórmula é adaptada para o problema de classificação. Para uma dada classe (C) e um conjunto de atributos ($A_1, A_2, \dots, A_n$), o objetivo é encontrar a classe com a maior probabilidade *a posteriori*, ou seja, $P(C | A_1, \dots, A_n)$.

A fórmula é expressa da seguinte maneira:

$$P(C | A_1, \dots, A_n) = \frac{P(A_1, \dots, A_n | C) \cdot P(C)}{P(A_1, \dots, A_n)}$$

Aqui, os termos significam:

- $P(C | A_1, \dots, A_n)$: A **probabilidade a posteriori**. É a probabilidade de que um determinado dado pertença à classe C , dadas as evidências (os atributos).
- $P(A_1, \dots, A_n | C)$: A **verossimilhança**. É a probabilidade de as evidências (atributos) ocorrerem, dado que o dado pertence à classe C .
- $P(C)$: A **probabilidade a priori**. É a probabilidade inicial de um dado pertencer à classe C , sem considerar nenhuma evidência.
- $P(A_1, \dots, A_n)$: A **probabilidade total das evidências**. É a probabilidade de os atributos ocorrerem, independentemente da classe.

O truque do Naive Bayes é aplicar a suposição de independência para simplificar o cálculo da verossimilhança. A verossimilhança $P(A_1, \dots, A_n | sC)$ é reescrita como um produto das probabilidades de cada atributo, dado o evento:

$$P(A_1, \dots, A_n | C) = \prod_{i=1}^n P(A_i | C)$$

Assim, a fórmula completa se torna:

$$P(C | A_1, \dots, A_n) = \frac{\prod_{i=1}^n P(A_i | C) \cdot P(C)}{P(A_1, \dots, A_n)} \quad (1)$$

Na prática, o termo $P(A_1, \dots, A_n)$ no denominador é uma constante para todas as classes, então ele pode ser desconsiderado na comparação. Logo, o numerador da Equação 1 retorna um valor proporcional para a verossimilhança para todas as classes.

$$P(C | A_1, \dots, A_n) \propto \prod_{i=1}^n P(A_i | C) \cdot P(C)$$

O classificador simplesmente escolhe a classe que maximiza o numerador de (1), resultando na Equação 2:

$$\text{Classificador}(A_1, \dots, A_n) = \arg \max_C \left(P(C) \cdot \left[\prod_{i=1}^n P(A_i | C) \right] \right) \quad (2)$$

O Naive Bayes é, portanto, um método de aprendizado de máquina que “aprende” as probabilidades dos atributos e das classes a partir dos dados de treinamento para, em seguida, classificar novos dados com base nas probabilidades calculadas.

Case: Planejamento de Vendas (adaptado de [5])

Exemplo 4: Planejamento de Vendas do Restaurante com Naive Bayes

Para exemplificar a aplicação do Naive Bayes, considere um cenário de planejamento de vendas em um restaurante, com o objetivo de prever se haverá maior saída de “Feijoada” ou “Filé à parmegiana” com base em condições climáticas. Assim, pode se planejar melhor para cada dia.

O conjunto de dados da Tabela 1, denominado **Planejamento de Vendas**, relaciona características do clima com o prato de maior saída. Considere um conjunto de 14 exemplares no total.

Tabela 1: Dataset ‘planejamento de vendas’

Exemplo #	A_1 PREVISAO	A_2 TEMPERATURA	A_3 HUMIDADE	A_4 VENTO	C VENDER
1	chuva	frio	normal	sim	parmegiana
2	chuva	moderado	alta	sim	parmegiana
3	sol	quente	alta	não	parmegiana
4	sol	quente	alta	sim	parmegiana
5	sol	moderado	alta	não	parmegiana
6	nublado	frio	normal	sim	feijoadada
7	nublado	quente	alta	não	feijoadada
8	nublado	quente	normal	não	feijoadada
9	nublado	moderado	alta	sim	feijoadada
10	chuva	frio	normal	não	feijoadada
11	chuva	moderado	alta	não	feijoadada
12	chuva	moderado	normal	não	feijoadada
13	sol	frio	normal	não	feijoadada
14	sol	moderado	normal	sim	feijoadada

Passo 1: Calcular as probabilidades a priori. A primeira ação é calcular a probabilidade de cada classe.

- A classe **Feijoadada** tem 9 ocorrências. A probabilidade a priori é:

$$P(\text{Feijoadada}) = \frac{9}{14} \approx 0,64$$

- A classe **Parmegiana** tem 5 ocorrências. A probabilidade a priori é:

$$P(\text{Parmegiana}) = \frac{5}{14} \approx 0,36$$

Passo 2: Avaliar um novo exemplar. Um novo exemplar com rótulo desconhecido, que representa um dia com as seguintes condições, é apresentado para ser classificado:

PREVISAO	TEMPERATURA	HUMIDADE	VENTO	VENDER
sol	frio	normal	sim	?

Passo 3: Calcular as probabilidades a posteriori.

Para classificar o novo exemplar, calculamos a probabilidade de ele pertencer a cada classe.

Cálculo para a classe “Feijoadá”:

$$\begin{aligned}
 &P(\text{Feijoadá} \mid \text{sol,normal,frio,sim}) \\
 &\quad \propto \\
 &P(\text{Feijoadá}) \cdot \left[P(\text{sol} \mid \text{Feijoadá}) \cdot P(\text{frio} \mid \text{Feijoadá}) \cdot P(\text{normal} \mid \text{Feijoadá}) \cdot P(\text{sim} \mid \text{Feijoadá}) \right]
 \end{aligned}$$

A partir das contagens do dataset, o cálculo das verossimilhanças é:

$$P(\text{sol} \mid \text{Feijoadá}) = \frac{2}{9}, \quad P(\text{frio} \mid \text{Feijoadá}) = \frac{3}{9}, \quad P(\text{normal} \mid \text{Feijoadá}) = \frac{6}{9}, \quad P(\text{sim} \mid \text{Feijoadá}) = \frac{3}{9}$$

A probabilidade *a posteriori* é:

$$P(\text{Feijoadá} \mid \text{sol,normal,frio,sim}) \propto \frac{9}{14} \cdot \left[\frac{2}{9} \cdot \frac{3}{9} \cdot \frac{6}{9} \cdot \frac{3}{9} \right] = 0,011$$

Cálculo para a classe “Parmegiana”:

$$\begin{aligned}
 &P(\text{Parmegiana} \mid \text{sol,normal,frio,sim}) \\
 &\quad \propto \\
 &P(\text{Parmeg.}) \cdot P(\text{sol} \mid \text{Parmeg.}) \cdot P(\text{frio} \mid \text{Parmeg.}) \cdot P(\text{normal} \mid \text{Parmeg.}) \cdot P(\text{sim} \mid \text{Parmegiana})
 \end{aligned}$$

A partir das contagens do dataset, o cálculo das verossimilhanças é:

$$P(\text{sol} \mid \text{Parmeg.}) = \frac{3}{5}, \quad P(\text{frio} \mid \text{Parmeg.}) = \frac{1}{5}, \quad P(\text{normal} \mid \text{Parmeg.}) = \frac{1}{5}, \quad P(\text{sim} \mid \text{Parmeg.}) = \frac{3}{5}$$

A probabilidade *a posteriori* é:

$$P(\text{Parmegiana} \mid \text{sol,normal,frio,sim}) \propto \frac{5}{14} \cdot \left[\frac{3}{5} \cdot \frac{1}{5} \cdot \frac{1}{5} \cdot \frac{3}{5} \right] = 0,005$$

Conclusão:

O resultado da multiplicação das probabilidades para a classe “Feijoada” (0,011) é maior do que para a classe “Parmegiana” (0,005). Portanto, o classificador Naive Bayes atribui a classe **Feijoada** ao novo exemplar.

Observe que, se o problema envolvesse mais classes, o processo seria o mesmo: calcula-se a verossimilhança para cada uma das classes envolvidas, e devolve-se aquela com maior valor, que é proporcional à probabilidade do novo exemplo estar na nova classe.

Pra saber mais: o excelente canal StatQuest possui diversos vídeos curtos e animados sobre aprendizado de máquinas. Isso inclui Naive Bayes: <https://www.youtube.com/watch?v=02L2Uv9pdDA>.

Peudocódigo

Nesta seção serão apresentados pseudocódigos para implementação de treinamento e classificação de exemplos usando o Naive Bayes.

Algoritmo 3 TreinaNaiveBayes(dados_treino)

```

1: p_prior ← ∅
2: p_condicional ← ∅
3: for cada classe 'c' em dados_treino do
4:   p_prior[c] ← count(c) / len(dados_treino)
5: end for
6: for cada classe 'c' em dados_treino do
7:   for cada atributo 'a' no dados_treino do
8:     for cada valor 'v' do atributo 'a' do
9:       p_condicional[a][v][c] ← count(a == v and c) / count(c)
10:    end for
11:  end for
12: end for
13: return p_prior, p_condicional = 0

```

Algoritmo 4 ClassificaNaiveBayes(p_prior, p_condicional, exemplo_novo)

```
1: melhor_probabilidade ← 0
2: classe_predita ← nulo

3: for cada classe 'c' em p_prior do
4:   prob_classe ← p_prior[c]

5:   for cada atributo 'a' no exemplo_novo do
6:     valor ← valor do atributo 'a' no exemplo_novo
7:     prob_cond ← p_condicional[a][valor][c]
8:     prob_classe ← prob_classe · prob_cond
9:   end for

10:  if (prob_classe > melhor_probabilidade) then
11:    melhor_probabilidade ← prob_classe
12:    classe_predita ← c
13:  end if
14: end for

15: return classe_predita = 0
```

Projeto Prático

Dado o que foi apresentado, pede-se que o grupo desenvolva um projeto prático em que implemente o método de Naive Bayes para classificação binária.

Pra tal, pede-se que algum dataset do *UC Irvine Machine Learning Repository*¹ seja escolhido para isso. Parte das tuplas serão usadas para treinar o modelo, e parte para verificar o quão bom ele foi em termos de acurácia, especificidade, e sensibilidade (o grupo deve estudar os conceitos).

A ideia central do projeto é, usando linguagem computacional, escrever um código que “contabiliza” as ocorrências dos eventos no *dataset* de treinamento para estimar a probabilidade de ocorrência dos mesmos de maneira *a priori*, e condicionada as classes.

Em seguida, pela Equação 2, determinar a qual classe uma nova observação deverá pertencer com base no dataset de verificação.

Sugestão de *datasets*:

- Mushroom: <https://archive.ics.uci.edu/dataset/73/mushroom>
- Breast Cancer: <https://archive.ics.uci.edu/dataset/15/breast+cancer+wisconsin+original>
- Lenses: <https://archive.ics.uci.edu/dataset/58/lenses>

No entanto, as opções não se limitam a estes *datasets*. O grupo terá liberdade de escolher qual conjunto de dados a utilizar, mas recomenda-se observar:

- Se os atributos são categóricos. Caso não sejam, será preciso ou (i) discretizar os valores, segundo alguma regra que precisa estar clara, ou (ii) substituir o cálculo das probabilidades

¹<https://archive.ics.uci.edu/>

de contagem para dados categóricos dentro da classe por cálculo de área sobre a curva via integração numérica, usando a função de densidade de probabilidade de alguma distribuição de probabilidades (por exemplo, considerando uma normal com média μ e desvio σ);

- Se existem dados faltantes. Em caso de falta, é preciso estimar os dados faltantes via algoritmos do tipo k -NN ou similar, se o exemplo incompleto for importante para a classificação, ou pela remoção do exemplo do *dataset* caso as classes não estejam desbalanceadas;
- Se o conjunto é usado tradicionalmente para classificação. No repositório UCI existem conjuntos adequados para agrupamentos, classificação e regressão, logo deve-se estudar a documentação do conjunto no referido site antes de tomar a decisão.
- O problema deve ser simples, com apenas duas classes, pois iremos usar a matriz de confusão para avaliar o classificador desenvolvido. Caso os dados possuam mais de 2 classes, deve-se eliminar os exemplos das classes em excesso.

A Matriz de Confusão

A avaliação de um classificador é crucial para entender seu desempenho e os tipos de erros que ele comete. Para isso, utilizamos métricas que são calculadas a partir da matriz de confusão.

Em nosso contexto, as métricas serão calculadas em um *conjunto de validação* ou *conjunto de teste*, obtido a partir de uma partição simples dos dados. Observe, entretanto, que a partição do conjunto de dados deve incluir exemplos de ambas as classes tanto no conjunto de teste, quanto no de validação, preferencialmente de maneira balanceada.

A matriz de confusão é uma tabela que resume os resultados do classificador, comparando as classes preditas com as classes reais. Para um problema de classificação binária (com classes “positiva” e “negativa”), a matriz é composta por quatro valores:

- **Verdadeiro Positivo (VP):** O modelo previu a classe positiva e a classe real era positiva.
- **Falso Positivo (FP):** O modelo previu a classe positiva, mas a classe real era negativa.
- **Verdadeiro Negativo (VN):** O modelo previu a classe negativa e a classe real era negativa.
- **Falso Negativo (FN):** O modelo previu a classe negativa, mas a classe real era positiva.

A estrutura da matriz de confusão é a seguinte:

Classe Real (y)	Classe Predita ($\hat{y}$)	
	Positiva	Negativa
Positiva	Verdadeiro Positivo (VP)	Falso Negativo (FN)
Negativa	Falso Positivo (FP)	Verdadeiro Negativo (VN)

Métricas de Desempenho

As células da matriz de confusão permitem o cálculo de métricas que fornecem uma visão mais detalhada sobre a performance do classificador.

- **Acurácia (Accuracy):** Mede a proporção total de predições corretas. É a métrica mais intuitiva, mas pode ser enganosa em datasets desbalanceados.

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

- **Sensibilidade (Sensitivity) ou Revocação (Recall):** Mede a proporção de casos positivos reais que foram corretamente identificados pelo modelo. É crucial quando o custo de um falso negativo (FN) é alto.

$$\text{Sensibilidade} = \frac{VP}{VP + FN}$$

- **Especificidade (Specificity):** Mede a proporção de casos negativos reais que foram corretamente identificados. É uma métrica importante quando o custo de um falso positivo (FP) é alto.

$$\text{Especificidade} = \frac{VN}{VN + FP}$$

- **Precisão (Precision):** Mede a proporção de predições positivas que estavam realmente corretas. É uma métrica importante quando o custo de um falso positivo (FP) é alto.

$$\text{Precisão} = \frac{VP}{VP + FP}$$

O uso combinado dessas métricas fornece uma avaliação mais robusta e completa do desempenho do classificador em um conjunto de dados de validação.

Referências

- [1] Kenneth H Rosen. *Discrete mathematics & applications*. McGraw-Hill, 1999.
- [2] Luiz Gonzaga Morettin. *Estatística básica: probabilidade e inferência: volume único*. Pearson Prentice Hall, 2010.
- [3] Douglas Montgomery et al. *Estatística aplicada e probabilidade para engenheiros*. LTC, 2009.
- [4] Ronald E Walpole. *Probabilidade & Estatística para engenharia e ciências*. Pearson Prentice Hall, 2009.
- [5] da Silva, Leandro Augusto and Peres, Sarajane Marques and Boscardioli, Clodis. *Introdução à mineração de dados: com aplicações em R*. Elsevier Brasil, 2017.
- [6] Castro, Leandro Nunes de and Ferrari, Daniel Gomes. *Introdução à mineração de dados: conceitos básicos, algoritmos e aplicações*. São Paulo: Saraiva, 2016. v. 5, p. 1-376.
- [7] Faceli, Katti and Lorena, Ana Carolina and Gama, João and Almeida, Tiago Agostinho de and Carvalho, André Carlos Ponce de Leon Ferreira de. *Inteligência artificial: uma abordagem de aprendizado de máquina*. 2021.